

请提供完整的待翻译深度生成以便进行精确翻译级面部妆容迁移的文本仅有一个

李婷婷 清华
克利深圳学院, 清华大
学 litt.thu@foxmail.com

钱瑞和 中国科学
院信息工程研究所 vitochien
09@gmail.com

东超 中国科学院深
圳先进技术研究院-商汤联合
实验室chao.dong@siat.ac.cn

刘思 北京航空航
天大学数字媒体北京市重点
实验室 计算机学院 liusi@bu
aa.edu.cn

颜琼 悟空科技
研究院 yanqiong@se
nsetime.com

朱文武
清华大学-伯克利深圳学院,
计算机科学与技术系, 清华大学
wwzhu@tsinghua.edu.cn

孙良林 中山
大学 linliang@iee
e.org

摘要

面部妆容转移的目标是从给定的参考化妆人脸图像中提取妆容风格, 并将其转移到另一张未化妆的人脸图像上, 同时保持面部身份不变。这种实例级别的转换问题比传统的领域级别转换任务更具挑战性, 尤其是在缺乏配对数据的情况下。与全局风格(如绘画)不同, 妆容由多个局部风格/化妆品组成, 包括眼影、口红、粉底等。现有的风格转移方法无法提取和传输这些局部且细微的化妆信息。我们通过在双输入输出生成对抗网络中结合全局领域级别损失和局部实例级别损失来解决这一问题, 并将其命名为BeautyGAN。具体而言, 领域级别的转换由区分生成图像与真实样本领域的判别器确保。实例级别的损失则通过对分离的局部面部区域进行像素级直方图损失计算得出。我们进一步引入感知损失和循环一致性损失以生成高质量的人脸并保持身份特征。整体目标函数使网络能够通过无监督对抗学习在实例级别上学习转换。此外, 我们建立了一个新的妆容数据集, 包含3834张高分辨率人脸图像。广泛的实验表明

BeautyGAN能够生成视觉上令人愉悦的化妆人脸, 并且转移效果准确。数据和代码可在<http://liusi-group.com/projects/BeautyGAN>获取。

CCS分类概念

• 计算方法论 → 计算机视觉任务; 神经网络; 无监督学习;

关键词

面部妆容转移; 生成对抗网络

ACM参考格式:

李婷婷, 钱瑞和, 董超, 刘思, 颜琼, 朱文武, 林良. 2018. BeautyGAN: 基于深度生成对抗网络的实例级面部妆容迁移. 在 ACM 多媒体会议 (MM '18), 2018年10月22日至26日, 韩国首尔. ACM, 美国纽约, 9页. <http://doi.org/10.1145/3240508.3240618>

1 引言

化妆是一种广泛使用特殊化妆品来改善面部外观的方式, 例如用粉底遮盖面部瑕疵、眼线笔、眼影和口红。面对成千上万种不同品牌、颜色及使用方式的化妆品产品, 没有专业人士的建议很难找到合适的妆容风格。虚拟化妆应用是一个方便的工具, 帮助用户通过照片尝试不同的妆容, 如美图秀秀、TAAZ 和 DailyMakeover 等。然而, 这些工具都需要用户的手动操作, 并且只提供有限数量的固定妆容选项。在日常生活中, 名人总是以美丽的妆容示人, 为其他人提供了参考范例。化妆迁移技术则为用户选择最适合自己的妆容风格提供了一种高效的方法。如图1所示, 我们的方法可以实现化妆迁移(结果展示)。

^{*}This work was done when Tingting Li and Ruihe Qian were interns at Sensetime.
[†]corresponding author

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than ACM must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.
MM '18, October 22–26, 2018, Seoul, Republic of Korea
© 2018 Association for Computing Machinery.
ACM ISBN 978-1-4503-5665-7/18/10...\$15.00
<https://doi.org/10.1145/3240508.3240618>

¹xiuxiu.web.meitu.com, taaz.com, dailymakeover.com




图1: 我们的BeautyGAN模型的妆容迁移示例结果。参考图像（顶行）上的三种妆容被转换为三个未化妆前的图像（左列）。中间展示了九个生成的图像。

将给定的参考人脸图像中的妆容风格转换到另一张未化妆的人脸上，同时保持面部身份不变。

现有自动化妆转移的研究可以分为两类：传统的图像处理方法[11, 19, 29]，如图像梯度编辑和基于物理的操纵，以及基于深度学习的方法，后者通常建立在深层神经网络的基础上[23]。图像处理方法一般将图像分解为若干层（例如面部结构、颜色、皮肤），并在将参考人脸图像扭曲到未化妆的人脸后转移每一层。基于深度学习的方法[23]采用几个独立的网络来分别处理每一种化妆品。几乎所有先前的方法都将妆容视为不同组件的简单组合，因此输出的整体图像看起来不自然，在结合处有明显的伪影（见图4）。

近期在图像到图像翻译领域的进展，如风格迁移[8, 9, 13]，表明端到端的结构可以对整个图像进行操作并生成高质量的结果。然而，在我们的任务中直接应用这些技术仍然不可行。面部化妆转换具有两个主要特征，与以往的问题有所不同：1) 化妆风格因人而异，并需要在实例级别上进行迁移。相反，基于生成对抗网络（GAN）的典型图像到图像翻译方法[4, 12, 35]主要用于领域级别的转换。例如，CycleGAN[35]实现了两个集合之间的图像到图像翻译（如马和斑马），强调跨域差异而忽略内部差异。因此，在我们的问题中使用CycleGAN往往会生成

平均域级别的风格，在不同参考人脸的情况下保持不变（参见图4）。2) 彩妆风格超越了全局风格，包含了独立的局部风格。具体来说，在传统的风格迁移工作中[8, 9, 13]，风格通常指的是像笔触和色彩分布这样的全局绘画方式。相比之下，彩妆风格更为细腻复杂，由眼影、口红、粉底等若干局部化妆品组成。每种化妆品代表一种完全不同的风格。因此，在保持各种化妆品特定特征的同时，很难整体提取出彩妆风格。

另一个关键问题在于缺乏训练数据。一方面，已发布的化妆数据集（见表1）规模太小，不足以训练一个足够大的网络，并且面部化妆图像大多分辨率和质量较低。另一方面，难以获取一对风格不同的、对齐良好的人脸图像。因此，使用配对数据进行监督学习也不切实际。

为了解决上述问题，我们提出了一种名为BeautyGAN的新型输入/输出生成对抗网络，在统一框架下实现妆容风格迁移。该网络接受化妆和未化妆的人脸作为输入，并直接输出转换结果，无需额外的预处理或后处理。类似于StyleGAN[35]，网络首先通过几个判别器将未化妆的脸部图像转移到化妆领域，这些判别器能够区分生成的图像与真实样本。在域级迁移的基础上，我们采用不同面部区域上的像素级直方图损失来实现实例级别的迁移。为了保持人脸身份并消除伪影，我们在整体目标函数中加入了感知损失和循环一致性损失。得益于双输入输出设计，在仅使用一个生成器的情况下即可实现输入与输出之间的循环一致性，从而在单次前向传递中同时完成化妆和去妆操作。此外，在整个训练过程中无需配对数据。如图1所示，生成的图像自然且美观，没有明显的伪影。

总之，主要贡献有三个方

- (1) 我们通过使用双输入输出的生成对抗网络实现了自动妆容迁移。实验展示了该迁移策略的有效性，生成的结果质量优于现有最先进的方法。
- (2) 我们在局部区域成功应用像素级直方图损失函数，从而实现实例级别的风格迁移。这种实例级别迁移的方法可以轻松推广到其他图像转换任务中，例如用于特写肖像的风格迁移、图像属性迁移等。
- (3) 我们建立了一个新的妆容数据集，该数据集中包含3834张图片，可在 <http://liusi-group.com/projects/BeautyGAN> 获取。

2 相关工作

2.1 调查研究

近期，与化妆相关的研究引起了更多的关注。[31]提出了一种基于局部约束字典学习的面部妆容检测和移除框架。[20]引入了对抗网络来生成无妆图像，用于化妆不变的人脸验证。妆容转换是另一个颇具吸引力的方向。

该应用程序旨在将参考图像中的妆容风格转移到源图像上，同时保持源图像的身份特征。[11] 将图像分解为三层，并逐层传输化妆信息。此方法可能会使源图像的面部细节变得平滑，因此[19] 引入了一种新的图像分解方法。上述所有妆容转移框架都基于传统方法，而[23] 则提出了一种基于深度学习的局部化妆容转移框架。该框架将面部化妆分为几个部分，并对每个面部部位采用不同的方法进行处理。通过使用变形和结构保留技术来合成化妆后的图像。

与前述工作不同，我们的网络能够同时实现妆容转移和卸妆妆容的功能。此外，统一的训练过程可以考虑不同区域化妆品之间的关系。更重要的是，端到端的网络本身能够学习源图像中输入化妆品的适应性，从而消除了后处理的需求。

2.2 风格转换

风格转换旨在结合来自不同图像的内容和风格。为了实现这一目标，文献[8]提出了一种通过最小化内容和风格重构损失来生成重建图像的方法。为了控制更多如颜色、尺度和空间位置等信息，文献[9]引入了感知因素并提出了改进方法。上述方法可以产生高质量的结果但需要大量的计算资源。文献[13]则提出了一种计算量较小且效果近似的前馈网络用于风格转换。

2.3 生成对抗网络

生成对抗网络（GANs）是一种生成模型，由判别器和生成器组成。由于其能够生成视觉上逼真的图像，GAN在计算机视觉任务中得到了广泛应用。文献[17]提出了一种用于图像超分辨率的生成对抗网络。文献[6]利用条件生成对抗网络（cGAN）解决了特定的眼部修复问题。文献[27]在合成图像上训练对抗模型以提高其逼真度。文献[34]甚至实现了将用户交互融入实时图像编辑中，其中使用GAN来估计图像流形。

2.4 基于GAN的图像到图像转换

现有的大多数关于图像到图像翻译的研究旨在学习从源域到目标域的映射。最近，有一些颇具前景的工作[4, 12, 35]将GAN应用于这一领域。文献[12]提出了一种所谓的pix2pix框架，该框架可以从标签图生成图像，并从边缘图像中重建对象。为了解决训练过程中缺乏配对图像的问题，文献[22]提出了一个模型，其生成器通过权重共享约束来学习联合分布。文献[35][14]则引入了循环一致性损失以规范输入与翻译后图像之间的关键属性。StarGAN[4]甚至在一个单一的生成器中解决了多个域之间映射的问题。特别地，文献[15]提出了一种与GAN配合工作的编码器用于图像属性转换。

3 我们的方法：BEAUTYGAN

我们的目标是在实例级别上实现从参考化妆图像到非化妆图像的面部妆容转移。考虑两个数据集， $A \subset \mathbb{R}^{H \times W \times 3}$ 表示非化妆图像域， $B \subset \mathbb{R}^{H \times W \times 3}$ 表示包含各种妆容样式的化妆图像域。我们同时学习这两个域之间的映射关系，记作 $G: A \times B \rightarrow B \times A$ ，其中 ‘ $\times$ ’ 代表笛卡尔积。也就是说，给定两张输入图片：一张源图 $I_{src} \in A$ 和一张参考图 $I_{ref} \in B$ ，网络期望生成一张化妆后的图像 $I_{Bsrc} \in B$ 和一张去妆后的图像 $I_{Aref} \in A$ ，记作 $(I_{Bsrc}, I_{Aref}) = G(I_{src}, I_{ref})$ 。 I_{Bsrc} 合成了 I_{ref} 的妆容风格同时保留了 I_{src} 的面部身份特征，而 I_{Aref} 实现了从 I_{ref} 中去除妆容的效果。基本问题是如何学习实例级别的对应关系，这应该确保结果图像 I_{Bsrc} 与参考图 I_{ref} 在妆容一致性方面的一致性。需要注意的是，在训练过程中没有配对数据可用。

为了解决这一问题，我们引入了针对不同化妆品的像素级直方图损失。此外，还采用了感知损失以保持面部身份和结构不变。这样就可以在不改变面部结构的情况下将确切的妆容转移到源图像上。所提出的方法基于生成对抗网络[10]，便于将所有损失项整合到一个完整的优化目标函数中。对抗性损失有助于生成视觉效果良好的图像，并细化不同化妆品之间的相关性。损失函数和网络架构的详细信息如下所示。

3.1 完整目标函数

如图2所示，整体框架包含一个生成器G和两个判别器：DA、DB。在公式 $(I_{Bsrc}, I_{Aref}) = G(I_{src}, I_{ref})$ 中，生成器G接受两张图像 $I_{src} \in A$ 和 $I_{ref} \in B$ 作为输入，并输出两张翻译后的图像 $I_{Bsrc} \in B$ 和 $I_{Aref} \in A$ 。

我们首先给出域适配器DA和DB的目标函数，这些目标函数仅包含对抗损失。给定集合A中的真实样本，域适配器DA区分生成的图像 I_{Aref} 与真实样本，表示为：

$$\mathcal{L}_{DA} = \mathbb{E}_{I_{src}} [\log D_A(I_{src})] + \mathbb{E}_{I_{src}, I_{ref}} [\log(1 - D_A(I_{Aref}))]. \quad (1)$$

类似地，DB旨在区分生成的图像 I_{Bsrc} 与集合B中的真实样本，表示为：

$$\mathcal{L}_{DB} = \mathbb{E}_{I_{ref}} [\log D_B(I_{ref})] + \mathbb{E}_{I_{src}, I_{ref}} [\log(1 - D_B(I_{Bsrc}))]. \quad (2)$$

生成器G的完整目标函数包含四种类型的损失：对抗损失、循环一致性损失、感知损失和化妆约束损失。

$$\mathcal{L}_G = \alpha \mathcal{L}_{adv} + \beta \mathcal{L}_{cyc} + \gamma \mathcal{L}_{per} + \mathcal{L}_{makeup}, \quad (3)$$

其中， ω_1 ， ω_2 ， ω_3 是控制每一项相对重要性的权重因子。生成器G的对抗损失整合了两项： $\mathcal{L}_{DA}$ 和 $\mathcal{L}_{DB}$

$$\mathcal{L}_{adv} = \mathcal{L}_{DA} + \mathcal{L}_{DB}. \quad (4)$$




图2: 提出的BeautyGAN框架。上行管道展示了整个系统。生成器G接受两张图片作为输入: 非化妆图像 I_{src} 和参考化妆图像 I_{ref} , 并产生两个输出: 转移后的化妆图像 I_{src}^B 和反向去妆图像 I_{ref}^A 。生成的图像被送入相同的生成器G以构建重建结果: I_{src}^{rec} , I_{ref}^{rec} 。训练生成器G时有四个损失项: 循环一致性损失、感知损失、对抗损失(分别表示为 D_A 和 D_B)以及化妆损失。下行管道展示了化妆损失的细节。它包括三个局部直方图损失项, 分别作用于面部、眼影和嘴唇区域。首先利用面部解析模型分离 I_{src} 、 I_{ref} 和 I_{src}^B 中的每个化妆品区域。然后, 对于每个区域, 我们通过在 I_{src} 和 I_{ref} 之间进行直方图匹配来获得作为地面真实值的重映射面部区域。局部损失项计算该地面真实值与 I_{src}^B 中相应化妆品区域之间的像素级差异。

注意, 生成器G与判别器 D_A 、 D_B 之间进行的是一个极小化-极大化的博弈, 其中生成器G试图最小化对抗损失, 而判别器 D_A 和 D_B 则力求最大化相同的损失函数。其余的三个损失将在后续章节中详细说明。

3.2 域级妆容迁移

我们利用领域级别的妆容转换作为实例级别妆容转换的基础。得益于双输入/输出架构, 所提出的网络能够在单一生成器内同时学习两个域之间的映射关系。输出图像需要保留与输入图像相同的人脸身份和背景信息。为了满足这两个约束条件, 我们分别施加感知损失和循环一致性损失。

本文不是直接测量像素级别的欧几里得距离差异, 而是计算由深度卷积网络提取的高层特征之间的差异。在本文中, 我们使用了在ImageNet数据集上预训练的16层VGG网络。对于一张图像 x , $F_l(x)$ 表示对应的特征。

在VGG的第 l 层中的特征图, 其中 $F_l \in \mathbb{R}^{C_l \times H_l \times W_l}$ 。 C_l 表示特征图的数量, H_l 和 W_l 分别表示每个特征图的高度和宽度。因此, 输入图像 I_{src} 、 I_{ref} 与输出图像 I_{src}^B 、 I_{ref}^A 之间的感知损失可以表示为:

$$\mathcal{L}_{per} = \frac{1}{C_l \times H_l \times W_l} \sum_{ijk} E_l \quad (5)$$

$$E_l = [F_l(I_{src}) - F_l(I_{src}^B)]_{ijk}^2 + [F_l(I_{ref}) - F_l(I_{ref}^A)]_{ijk}^2, \quad (6)$$

其中 $F_{l,ijk}$ 是第 l 层中第 i 个滤波器在位置 (j,k) 处的激活值。

为了保持背景信息, 我们还引入了周期一致性损失。当输出图像被送入生成器时, 它应该生成与原始输入图像尽可能接近的图像。这一过程可以表示为

$$(I_{src}, I_{ref}) \rightarrow G(I_{src}, I_{ref}) \rightarrow G(G(I_{src}, I_{ref})) \approx (I_{src}, I_{ref}). \quad (7)$$

The loss function is formulated as

$$\mathcal{L}_{cyc} = \mathbb{E}_{I_{src}, I_{ref}} [dist(I_{src}^{rec}, I_{src}) + dist(I_{ref}^{rec}, I_{ref})], \quad (8)$$

其中 $(I_{src}, I_{ref}) = G(G(I_{src}), G(I_{ref}))$ 。距离函数 $dist(\cdot)$ 可以选择为 L1 范数、L2 范数或其他度量标准。

3.3 实例级妆容迁移

为了进一步鼓励网络学习实例级别的妆容转移，必须添加关于妆容风格一致性的约束。我们观察到面部妆容可以被视作颜色分布来进行视觉识别。无论是口红、眼影还是粉底，化妆过程主要可以理解为颜色的变化。在文献[7]中可以找到多种颜色迁移方法。我们采用直方图匹配（Histogram Matching, HM）这一简单的方法，并引入像素级别的额外直方图损失，以限制输出图像 I_{Bsrc} 和参考图像 I_{ref} 在妆容风格上保持一致。

直方图损失。如果我们直接在两张图像的像素级直方图上采用均方误差（MSE）损失函数，由于指示函数的存在，梯度将会为零，从而对优化过程没有贡献。因此，我们采用了直方图匹配策略，在此策略中提前生成一个真实的重映射图像。假设我们要计算原始图像 $I(x)$ 和参考图像 $I(y)$ 之间像素的直方图损失，首先需要在 $I(x)$ 和 $I(y)$ 上执行直方图匹配以获得重映射图像 $I(HM(x, y))$ ，该图像具有与参考图像相同的颜色分布但仍然保留了原始图像的内容信息。获取到 $I(HM(x, y))$ 后，我们可以方便地利用 $I(HM(x, y))$ 和 $I(x)$ 之间的均方误差损失，并反向传播梯度以进行优化。

面部解析。我们不采用在整个图像上计算直方图损失的方法，而是将妆容风格拆分为三个重要组成部分——口红、眼影和粉底。最先进的方法如[23]也将这三个部分作为妆容表示。然后我们在每个部分应用局部化直方图损失。原因有两点。首先，背景和头发的像素与妆容无关。如果不将其分离出来，它们会干扰正确的颜色分布。其次，面部妆容不仅仅是全局风格，而是不同化妆品区域中几个独立风格的集合。因此，我们采用文献[32]中的面部解析模型来获取面部引导掩码 $M = FP(x)$ 。对于每个输入图像 x ，预训练的面部解析模型会生成一个索引掩码 M ，表示多个面部位置，包括嘴唇、眼睛、脸部皮肤（对应于粉底）、头发、背景等。最后，对于每个 M ，我们跟踪不同的标签以产生三个对应的二值掩码，代表化妆品的空间性： M_{lip} 、 M_{eye} 和 M_{face} 。值得注意的是，眼影在 M 中没有标注，因为化妆前的图像中没有眼影。但我们期望结果图像 I_{Bsrc} 具有与参考图像 I_{ref} 相似的眼影颜色和形状。根据眼睛掩码 M_{eye} ，我们计算两个矩形区域以包围眼影，并排除其中的眼睛、一些头发和眉毛区域。因此我们可以创建一个特定的二值掩码代表眼影 M_{shadow} 。

补救损失。总体的补救损失通过作用于嘴唇、眼影和面部区域的三个局部直方图损失进行整合。



图3：来自MT数据集的样本。上行为未化妆图像，下行为化妆图像。

表1：与已发布化妆数据集的比较。

Dataset	Subjects	Images per subject	Total number of images
YMU[2]	151	4	604
VMU[5]	51	4	204
MIW[1]	125	1-2	154
MIFS[3]	214	4 or 2	642
Ours(MT)	3000+	1-2	3834

分别：

$$\mathcal{L}_{makeup} = \lambda_l \mathcal{L}_{lips} + \lambda_s \mathcal{L}_{shadow} + \lambda_f \mathcal{L}_{face}, \quad (9)$$

其中 λ_l , λ_s , λ_f 是权重因子。我们将图像与其对应的二值掩码相乘，并在结果图像 I_{Bsrc} 和参考图像 I_{ref} 之间进行空间直方图匹配处理。形式上，我们定义局部直方图损失为

$$\mathcal{L}_{item} = \|I_{src}^B - HM(I_{src}^B \circ M_{item}^1, I_{ref} \circ M_{item}^2)\|_2. \quad (10)$$

$$M^1 = FP(I_{src}^B) \quad (11)$$

$$M^2 = FP(I_{ref}) \quad (12)$$

这里， $\circ$ 表示逐元素乘法，项属于集合 {嘴唇、阴影、面部}。

4 数据收集

我们收集了一个新的面部化妆数据集，包含总计3834张女性图像，其中1115张为未化妆图像，2719张为化妆图像。我们将该数据集命名为 Makeup Transfer (MT) 数据集。它包括种族、姿态、表情和背景杂乱程度的变化。汇集了多种化妆风格，包括烟熏妆、哑光妆、复古妆、韩式妆和日系妆等，从淡雅到浓重不一而足。具体而言，有一些裸妆图像，为了方便分类，被归入未化妆类别中。

初始数据从网站上抓取。我们手动移除了不良光照条件下分辨率较低的图像。然后，保留下来的图像被用于进行包含68个特征点的脸部对齐。根据两个眼睛的位置，我们将它们转换为相同的标准位置。

空间大小为256×256。在3834张图像中，我们随机选取了100张未化妆的图像和250张化妆的图像作为测试集。其余图像被划分为训练集和验证集。

MT是目前最大的化妆数据集，与其他已发布的化妆数据集相比规模更大。现有的化妆数据集通常包含不超过1000张图像。它们一般由同一对象的成对图片组成：妆前和妆后照片。尽管这些配对图片中的对象相同，但视角、姿态甚至光照条件都有所不同。这类数据集主要用于研究化妆对面部识别的影响，而不适用于化妆迁移任务。MT数据集包含多种化妆风格，并且涉及超过3000个不同的对象。各类化妆数据集的详细对比见表1。图3展示了MT数据集的一些示例。

5 实验

在本节中，我们描述了网络架构和训练设置。所有实验均使用我们发布的同一机器翻译数据集。从定性和定量两个角度比较了我们的方法和其他一些基准方法的性能。此外，我们还对BeautyGAN的各个组件进行了全面分析。

5.1 实现细节

网络架构。我们设计生成器G，使其具有两个输入和两个输出。具体来说，该网络包含两条独立的输入分支，每条分支都进行了卷积操作。在中间部分，我们将这两条分支连接在一起，并将其馈入若干残差块中。之后，通过两条独立的转置卷积分支对输出特征图进行上采样以生成两张结果图像。需要注意的是，各层内的分支不共享参数。我们还为G使用了实例归一化[30]。至于判别器DA和DB，我们采用了相同的70×70 PatchGANs [18]，用于分类局部重叠的图像块是真实图像还是假图像。

训练细节。为了稳定训练过程并生成高质量图像，我们使用了两种额外的训练策略。首先，受[35]启发，我们将对抗损失中的所有负对数似然目标替换为最小二乘损失[24]。例如，方程1定义如下，同样适用于方程2和4：

$$\mathcal{L}_{DA} = \mathbb{E}_{I_{src}} [(D_A(I_{src}) - 1)^2] + \mathbb{E}_{I_{src}, I_{ref}} [D_A(I_{ref}^A)^2]. \quad (13)$$

其次，我们引入谱归一化[26]以稳定地训练判别器。它计算成本低且易于集成，满足利普希茨约束 $\|W\|_{\text{op}} \leq 1$ 。

$$W_{SN}(W) := \frac{W}{\sigma(W)}, \quad (14)$$

其中 $\|W\|_{\text{spec}}$ 表示 W 的谱范数，记为：

$$\sigma(w) := \max_{h: \|h\|_2=1} \|Wh\|_2 = \max_{\|h\|_2 \leq 1} \|Wh\|_2, \quad (15)$$

在这里，h 是每一层的输入。

对于所有实验，我们通过一个经过人脸分割训练的PSPNet[33]获得了不同面部区域的掩码和标注标签。使用VGG16[28]网络的relu_4_1特征层来保持身份信息。这样的VGG16是在ImageNet上预训练过的。

参数在整个训练过程中保持固定。方程3和9中的参数为： $\beta = 1$ ， $\gamma = 10$ ， $\alpha = 0.005$ ， $\lambda = 1$ ， $\mu = 1$ ， $\nu = 0.1$ 。我们使用Adam[16]从头开始训练网络，学习率为0.0002，批处理大小为1。

5.2 基线方案

数字面部美妆[11]是一项早期的妆容迁移工作，采用了传统的图像处理方法。

DTN[23]是当前最先进的化妆转移工作。它提出了一种深度局部化妆转移网络，该网络能够独立转移不同的化妆品。

深度图像类比[21]是一项近期工作，其实现了在两张语义相关图像之间进行视觉属性转移。它将图像类比技术应用于匹配从深层神经网络提取的特征。我们将该方法应用到化妆转换任务中以作比较。

CycleGAN[35]是一种典型的无监督图像到图像翻译工作。为了适应化妆转移任务，我们在其中修改生成器以包含两个输入分支，但保持所有其他架构和设置不变。

风格转换[13]是一项相关工作，它训练了一个前馈网络来从相应图像中合成风格和内容信息。我们在实验中采用非化妆图像作为内容图像，并使用参考化妆图像作为风格图像。

5.3 与基准的对比

定性评估。如图4所示，我们展示了与基准方法的定性比较结果。观察发现，虽然Guo等人[11]生成了带有妆容的照片，但所有结果都存在可见的伪影。这些伪影看起来像是在未化妆的脸上贴了一张假面具。面部和眼睛轮廓处出现了不匹配的问题。一些细节被错误地转移，例如第二行和第四行的眼睛阴影从黑色变成了蓝色。Liu等人[23]独立传输不同的化妆品，因此在眼部区域和唇部区域显示了对齐伪影。底妆和眼影也没有正确传输。风格迁移[13]生成的图像引入了类似颗粒状的伪影，这降低了图像质量。它通常会转移全局样式如绘画笔触，因此不适合精细化妆样式的转换。与上述方法相比，CycleGAN[35]可以生成相对逼真的图像。然而，所生成的妆容风格并不一致于参考图片。Liao等人[21]产生的输出具有类似于参考图样的妆容，并且显示了自然的结果。但是，它不仅传输面部化妆，还转移参考图像中的其他特征。例如，第三张图片将背景颜色从黑色变为灰色，第四张图片改变了头发颜色，所有图片都将瞳孔颜色修改得像参考图样一样。此外，它传输的妆容比参考图样的更淡，特别是在唇膏和眼影方面。

与基线方法相比，我们的方法能够生成高质量的图像，并且无论是在眼影、口红还是粉底方面，都能准确地呈现化妆风格。例如，在第二行中，只有我们的结果成功转移了参考图中的深色眼影。实验结果还表明，BeautyGAN能够保持其他与化妆无关的成分（如头发、衣服和背景）与原始未化妆图像一致。在图5中，我们进行了放大展示



图4: BeautyGAN与基准方法的定性比较。前两列分别为非化妆图像和参考图像，其余各列中的每一行展示了不同方法的妆容迁移结果。




图5: 眼部化妆和唇膏转移的性能放大示意。

为了更好地展示对比效果，在眼妆和口红的转移性能上进行了测试。更多结果请参见补充文件。

定量比较。为了对BeautyGAN进行定量评估，我们从84名志愿者中进行了用户研究。我们随机选择了10张非化妆测试图像和20张化妆测试图像。

为了获得每种化妆转移方法的10×20次化妆后的结果。两个具有代表性的基线进行比较：廖等人[21]和刘等人[23]。每次我们呈现五张图片，包括一张未化妆的照片、一张作为参考的化妆照片以及三张由不同方法生成的随机打乱顺序的化妆转移照片。参与者被指示给出一个排名顺序。




图6：消融实验结果。前两列分别为非化妆图像和参考图像。其余各列的每一行展示了五个不同实验（A、B、C、D、E）的妆容迁移效果。不同的实验设置如表2所示。

表2：消融实验设置

Setup	$\mathcal{L}_{per}$	$\mathcal{L}_{face}$	$\mathcal{L}_{eye-shadow}$	$\mathcal{L}_{lips}$
A		✓	✓	✓
B	✓			
C	✓	✓		
D	✓	✓	✓	
E	✓	✓	✓	✓

表3：用户研究结果。

Methods	Rank 1	Rank 2	Rank 3
Liu[23]	4.25%	10.78%	84.97%
Liao[21]	33.91%	46.03%	20.06%
Ours	61.84%	27.56%	10.59%

基于质量、真实感和妆容风格相似度，对三个生成的图像进行排名。排名第一表示最佳的妆容迁移效果，而排名第三则表示最差的妆容迁移效果。

表3展示了结果。对于每种方法，我们将票数进行归一化，并获得三种排名顺序的百分比。BeautyGAN排名第一的比例为61.84%，相比之下Liao等人的比例为33.91%，而Liu等人的比例仅为4.25%。此外，BeautyGAN在第三名中的占比最低。我们观察到，BeautyGAN主要被投票为第一名，Liao等人则主要分布在第二名，而Liu等人则主要集中在第三名。用户研究证明了我们的方法优于其他基准方法。

5.4 BeautyGAN组件分析

为了探究每个组件在总体目标函数（公式3）中的重要性，我们进行了消融实验。主要分析感知损失项（公式5）和妆容损失项（公式9）的影响。因此，在所有实验中都同时采用了对抗损失和循环一致性损失。表2展示了实验设置，图6显示了实验结果。

在实验A中，我们从公式(3)中移除感知损失项。在这种情况下，所有结果都是类似两个输入的假图像。

扭曲和合并像素。相反，其他包含感知损失项的实验表明，未化妆的脸部身份得以保持。因此，这表明感知损失有助于保留图像的身份。

实验B、C、D和E旨在研究化妆损失项，该损失项由三个作用于不同化妆品区域的局部直方图损失组成： $\mathcal{L}_{face}$ （面部）、 $\mathcal{L}_{shadow}$ （阴影）和 $\mathcal{L}_{lips}$ （唇部）。在实验B中，我们直接从公式3中移除化妆损失。结果发现生成的图像仅在肤色和口红上略有修改，并未从参考图像中转移妆容风格。随后，在实验C、D和E中依次添加了 $\mathcal{L}_{face}$ （面部）、 $\mathcal{L}_{shadow}$ （阴影）和 $\mathcal{L}_{lips}$ （唇部）。列C显示底妆可以从参考图像成功转移到目标图像上。基于底妆的转移，实验D增加了眼影约束 $\mathcal{L}_{shadow}$ （阴影），我们观察到局部眼部化妆也被转移了。列E展示了整体化妆损失训练的结果，与列D相比，口红也得到了额外的转移。总之，化妆损失对于实例级别的妆容转移是必要的，三个化妆损失项分别对底妆、眼影和唇部的转移起作用。

6 结论与未来工作

在本文中，我们提出了一种用于实例级面部化妆转移的双输入/输出BeautyGAN。通过一个生成器，BeautyGAN能够在一次前向传递中同时实现化妆和卸妆。我们引入了像素级别的直方图损失来约束化妆风格的相似性。感知损失和循环一致性损失已被采用以保持身份特征。实验结果表明，我们的方法可以显著优于现有方法的表现。

致谢：本研究得到了国家重点基础研究发展计划（编号：2015CB352300）、国家自然科学基金重大项目（编号：U1611461）、国家自然科学基金（编号：U1536203，61572493）、中国科学院国际合作项目（编号：Y6Z0021102，Y7Z0241102）、中国计算机学会-腾讯开放研究基金以及中国科学院国际合作伙伴计划（编号：172644KYSB20160033）的支持。

参考文献

[1] 陈存健, Antitza Dantcheva 和 Arun Ross. 2013. 自动面部化妆检测及其在人脸识别中的应用。《生物识别学国际会议论文集》(ICB), IEEE 出版, 第 1-8 页。[2] 陈存健, Antitza Dantcheva, Thomas Swearingen 和 Arun Ross. 2016. 基于补丁子空间的化妆鲁棒人脸识别方法。《信息融合》32 (2016), 第 80-92 页。[3] 陈存健, Antitza Dantcheva, Thomas Swearingen 和 Arun Ross. 2017. 使用化妆伪造面部的研究性研究。《身份、安全与行为分析国际会议论文集》(ISBA), IEEE 出版, 第 1-8 页。[4] Yunje Choi, Minje Choi, Munyoung Kim, Jung-Woo Ha, Sunghun Kim 和 Jaegul Choo. 2017. StarGAN: 多域图像到图像转换的统一生成对抗网络。arXiv 预印本 arXiv:1711.09020 (2017)。[5] Antitza Dantcheva, 陈存健 和 Arun Ross. 2012. 面部化妆品是否会影响人脸识别系统的匹配精度?《生物识别学理论、应用与系统国际会议论文集》(BTAS), IEEE 出版, 第 391-398 页。[6] Brian Dolhansky 和 Cristian Canton Ferrer. 2017. 基于示例生成对抗网络的眼部修复技术。arXiv 预印本 arXiv:1712.03999 (2017)。[7] Hasan Sheikh Faridul, Tania Pouli, Christel Chamaret, Jürgen Staude r, Alain Trémeau, Erik Reinhard 等. 2014. 色彩映射及其应用综述。《Eurographics》(状态报告) 3 (2014)。[8] Leon A Gatys, Alexander S Ecker 和 Matthias Bethge. 2015. 神经艺术风格算法。arXiv 预印本 arXiv:1508.06576 (2015)。[9] Leon A Gatys, Alexander S Ecker, Matthias Bethge, Aaron Hertzmann 和 Eli Shechtman. 2017. 控制神经风格转换中的感知因素。《IEEE 计算机视觉与模式识别会议论文集》。[10] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville 和 Yoshua Bengio。2014. 生成对抗网络。《神经信息处理系统进展》论文集, 第 2672-2680 页。[11] 谷东和 Sim Terence. 2009. 基于示例的数字面部化妆技术。《计算机视觉与模式识别会议论文集》, IEEE 出版, 第 73-79 页。[12] Phillip Isola, Jun-Yan Zhu, Tinghui Zhou 和 Alexei A Efros. 2016. 条件生成对抗网络的图像到图像转换技术。arXiv 预印本 arXiv:1611.07004 (2016)。[13] Justin Johnson, Alexandre Alahi 和 Li Fei-Fei. 2016. 实时风格转移与超分辨率的感知损失方法。《欧洲计算机视觉会议论文集》, Springer 出版, 第 694-711 页。[14] Taeksoo Kim, Moonsu Cha, Hyunsoo Kim, Jungkwon Lee 和 Jiwon Kim. 2017. 使用生成对抗网络学习跨域关系的方法。arXiv 预印本 arXiv:1703.05192 (2017)。[15] Taeksoo Kim, Byoungjip Kim, Moonsu Cha 和 Jiwon Kim. 2017. 基于可重构生成对抗网络的无监督视觉属性转移方法。arXiv 预印本 arXiv:1707.09798 (2017)。[16] Diederik P Kingma 和 Jimmy Ba. 2014. Adam: 一种随机优化方法。arXiv 预印本 arXiv:1412.6980 (2014)。[17] Christian Ledig, Lucas Theis, Ferenc Huszár, Jose Caballero, Andrew Cunningham, Alejandro Acosta, Andrew Aitken, Alykhan Tejani, Johannes Totz, Zehan Wang 等. 2016. 基于生成对抗网络的单幅图像超分辨率技术。arXiv 预印本 arXiv:1609.04802 (2016)。

[18] 李川和万迈克。2016. 基于马尔可夫生成对抗网络的预计算实时纹理合成。欧洲计算机视觉会议论文集, Springer出版社, 第702-716页。[19] 陈莉、周坤和林斯蒂芬。2015. 通过物理基础操作内在图像层模拟化妆。IEEE计算机视觉与模式识别会议论文集, 第4621-4629页。[20] 李毅、宋灵晓、吴翔、何然和谭天佑。2017. Anti-Makeup: 学习用于无妆人脸识别的双层对抗网络。arXiv预印本 arXiv:1709.03654 (2017)。[21] 廖品、姚远、袁露、华刚和康星炳。2017. 通过深度图像类比进行视觉属性转移。ACM Transactions on Graphics (TOG), 第36卷, 第4期 (2017), 论文编号120。[22] 刘明宇和奥内尔·图泽尔。2016. 耦合生成对抗网络。神经信息处理系统进展会议论文集, 第469-477页。[23] 刘思、欧鑫宇、钱瑞和、王伟和曹晓春。2016. 像超级明星一样化妆: 深度局部化妆容转换网络。人工智能促进协会年会论文集, AAAI出版社, 第2568-2575页。[24] 茅旭东、李庆、谢浩然、刘延凯和王振。2016. 多类生成对抗网络与L2损失函数。arXiv预印本 abs/1611.04076 (2016)。arXiv:1611.04076 <http://arxiv.org/abs/1611.04076>[25] 米尔迪·米尔扎和西蒙·奥斯特因德罗。2014. 条件生成对抗网络。arXiv预印本 arXiv:1411.1784 (2014)。[26] 宫田拓郎、加藤知基、小山雅纪和吉田雄一。2018. 用于生成对抗网络的谱归一化。arXiv预印本 arXiv:1802.05957 (2018)。[27] 阿希什·沙里瓦斯塔瓦、托马斯·波斯特、奥内尔·图泽尔、乔什·萨金德、王文达和鲁斯·韦布。2016. 通过对抗训练从模拟和无监督图像中学习。arXiv预印本 arXiv:1612.07828 (2016)。[28] 科林·辛蒙扬和阿德里安·齐泽曼。2014. 用于大规模图像识别的非常深卷积网络。arXiv预印本 abs/1409.1556 (2014)。[29] 汤伟顺、唐启康、布朗迈克和许英青。2007. 基于示例的化妆品转移。计算机图形学与应用, 第15届太平洋会议论文集, IEEE出版社, 第211-218页。[30] 德米特里·乌利亚诺夫、安德烈亚·韦达尔迪和维克多·S·列姆皮茨基。2016. 实例归一化: 快速风格化的缺失成分。arXiv预印本 arXiv:1607.08022 (2016)。arXiv:1607.08022 <http://arxiv.org/abs/1607.08022>[31] 王书阳和傅云。2016. 化妆背后的面孔。人工智能促进协会年会论文集, 第58-64页。[32] 魏振、孙瑶、王进桥、赖汉江和刘思。2017. 学习用于深度图像解析网络的自适应感受野。IEEE计算机视觉与模式识别会议论文集, 第2434-2442页。[33] 赵恒爽、石建平、祁晓娟、王小刚和贾佳亚。2017. 金字塔场景解析网络。IEEE计算机视觉与模式识别会议论文集, 第2881-2890页。[34] 朱俊彦、菲利普·克雷恩布赫尔、艾利·谢赫特曼和阿列克谢·A·埃弗罗斯。2016. 自然图像流形上的生成视觉操作。欧洲计算机视觉会议论文集, Springer出版社, 第597-613页。[35] 朱俊彦、朴泰松、菲利普·伊索拉和阿列克谢·A·埃弗罗斯。2017. 无配对图像到图像转换的循环一致对抗网络。arXiv预印本 arXiv:1703.10593 (2017)。