

# 面向现实世界的盲人脸复原研究——基于生成面部先验方法

王晓鑫 李宇 张宏伦 单颖 腾讯G应用研究平台 (ARC) {xintawang, ianyli, honlanzhang, yingsshan}@tencent.com <https://github.com/TencentARC/GFPGAN>




图1: 与最先进的面部恢复方法的比较: HiFaceGAN [67]、DFDNet [44]、Wan *et al.* [61] 和 PULSE [52] 在真实世界低质量图像上的表现。虽然之前的方法难以恢复真实的面部细节或保留人脸身份, 我们的提出的GFP-GAN在逼真度和保真度之间取得了良好的平衡, 并且生成的伪影显著减少。此外, 强大的生成式面部先验使我们能够同时进行恢复和色彩增强。(放大查看最佳效果)

## 摘要

*Blind face restoration usually relies on facial priors, such as facial geometry prior or reference prior, to restore realistic and faithful details. However, very low-quality inputs cannot offer accurate geometric prior while high-quality references are inaccessible, limiting the applicability in real-world scenarios. In this work, we propose GFP-GAN that leverages rich and diverse priors encapsulated in a pretrained face GAN for blind face restoration. This Generative Facial Prior (GFP) is incorporated into the face restoration process via spatial feature transform layers, which allow our method to achieve a good balance of realness and fidelity. Thanks to the powerful generative facial prior and delicate designs, our GFP-GAN could jointly restore facial details and enhance colors with just a single forward pass, while GAN inversion methods require image-specific optimization at inference. Extensive experiments show that our method achieves superior performance to prior art on both synthetic and real-world datasets.*

## 1. 引言

盲脸复原旨在从遭受未知退化(如低分辨率[13, 48, 9]、噪声[71]、模糊[39, 58]、压缩伪影[12])的低质量人脸图像中恢复高质量的人脸。当应用于实际场景时, 由于更复杂的退化情况以及多样的姿态和表情, 任务变得更加具有挑战性。以往的工作[9, 69, 6]通常利用特定于面部的先验知识进行面部复原, 例如面部标志点[9]、解析图[6, 9]、面部组件热图[69], 并表明这些方法对于恢复准确的人脸形状和细节至关重要。然而, 这些先验知识通常是根据输入图像估计得出的, 在实际中面对非常低质量的输入时不可避免地会退化。此外, 尽管它们提供了语义指导, 但上述先验知识包含有限的纹理信息用于恢复面部细节(如瞳孔)。

另一种方法类别研究的是高质量引导人脸[reference priors, i.e.]或面部[46, 45, 11]。

组件字典 [44] 可以生成逼真的结果并缓解对质量下降的输入数据的依赖。然而，高分辨率参考数据的不可获取性限制了其实际应用，而字典容量的有限性则制约了面部细节的多样性和丰富度。

在这项研究中，我们利用 *Generative Facial Prior* (GFP) 进行实际场景中的盲人脸复原，即在预训练的面部生成对抗网络 (GAN) [18] 模型（如 StyleGAN [35, 36]）中隐含封装的先验知识。这些面部 GAN 能够生成具有高度变化性的逼真面孔，并提供丰富的多样化的先验信息，例如几何结构、面部纹理和颜色，从而使得同时复原面部细节并增强色彩成为可能（图1）。然而，将此类生成式先验融入到复原过程中颇具挑战性。以往的尝试通常采用 GAN 逆向映射 [19, 54, 52] 的方法。它们首先将退化图像“逆向”转换为预训练 GAN 中的潜在代码，然后进行昂贵的特定图像优化以重建图像。尽管输出视觉上非常逼真，但这些方法生成的图像通常保真度较低，因为低维潜在代码不足以引导准确复原。

为了应对这些挑战，我们提出了 GFP-GAN，并通过精心设计在单次前向传递中实现了真实性和保真度的良好平衡。具体来说，GFP-GAN 包含一个降质去除模块和一个预训练的面部 GAN 作为面部先验。它们通过直接隐码映射连接起来，并以从粗到细的方式嵌入了几层通道分割空间特征变换 (CS-SFT) 层。所提出的 CS-SFT 层对特征的一部分进行 *spatial* 调制，而让另一部分直接传递，从而更好地保留信息，使我们的方法能够在生成先验的同时保持高保真度。此外，我们引入了带有局部判别器的面部组件损失以进一步增强感知面部细节，并采用身份保持损失进一步提高保真度。

我们总结贡献如下：(1) 我们利用丰富多样的生成式面部先验进行盲人脸复原。这些先验包含了足够的面部纹理和色彩信息，使我们能够同时完成面部复原和色彩增强。(2) 我们提出了 GFP-GAN 框架，并通过精心设计的架构和损失函数来整合生成式面部先验。我们的 GFP-GAN 结合 CS-SFT 层，在单次前向传递中实现了保真度与纹理忠实性的良好平衡。(3) 大量实验表明，我们的方法在合成数据集和真实世界数据集中均优于现有技术。

## 2. 相关工作

图像恢复通常包括超分辨率处理 [13, 48, 60, 49, 74, 68, 22, 50]、去噪 [71, 42, 26]、去模糊 [65, 39, 58] 和解压缩处理 [12, 21]。

为了获得视觉上令人满意的结果，通常会使用生成对抗网络 [18] 作为损失监督，以将解决方案推向自然流形 [41, 57, 64, 7, 14]，而我们的工作则尝试利用预训练的面部 GAN 作为生成性面部先验 (GFP)。

面部修复。基于通用的面部超分辨率技术 [5, 30, 66, 70]，我们融合了两种典型的面部特定先验知识：几何先验和参考先验，以进一步提升性能。几何先验包括面部关键点 [9, 37, 77]、面部解析图 [58, 6, 9] 以及面部组件热力图 [69]。然而，1) 这些先验知识需要从低质量输入中进行估计，在实际场景中不可避免地会退化；2) 它们主要关注几何约束，可能不包含足够的细节用于修复。相反，我们采用的 GFP 不需要显式地从受损图像中估计几何信息，并且其预训练网络内部包含了充足的纹理细节。

参考先验 [46, 45, 11] 通常依赖于同一身份的参考图像。为了解决这一问题，DFD-Net [44] 建议构建每个面部组件（如眼睛、嘴巴）的 CNN 特征字典来指导恢复过程。然而，DFD-Net 主要关注字典中的组件，在超出其字典范围的区域（如头发、耳朵和脸部轮廓）性能会下降。相比之下，我们的 GFP-GAN 可以将整个面部视为一个整体来进行恢复。此外，受限于字典大小，其多样性和丰富性受到限制，而 GFP 能够提供包括几何形状、纹理和颜色在内的丰富多样的先验信息。

预训练 GAN 的生成先验 [34, 35, 36, 3] 此前已被 GAN 逆向工程 [1, 76, 54, 19] 利用，其主要目的是找到给定输入图像对应的最接近的潜在代码。PULSE [52] 通过迭代优化 StyleGAN [35] 的潜在代码，直到输出与输入之间的距离低于阈值为止。mGANprior [19] 尝试优化多个代码以提高重建质量。然而，这些方法通常会产生低保真度的图像，因为低维潜在代码不足以指导恢复过程。相比之下，我们提出的 CS-SFT 调制层能够在多分辨率空间特征上引入先验知识，从而实现高保真度。此外，在我们的 GFP-GAN 推理过程中不需要昂贵的迭代优化。

通道拆分操作通常被用于设计紧凑型模型并提升模型的代表能力。MobileNet [28] 提出了深度可分离卷积，而 GhostNet [23] 将卷积层分为两部分，并使用较少的滤波器生成固有特征图。DPN [8] 中的双路径架构允许每条路径重复利用特征并探索新特征，从而提升其表示能力。类似的思想也被应用于超分辨率领域 [75]。我们的 CS-SFT 层具有相似的精神，但采用了不同的操作和目的。我们在一个拆分部分采用空间特征变换 [63, 55]。




图2: GFP-GAN框架概述。该框架由一个降质去除模块（U-Net）和一个预训练的面部GAN作为面部先验组成。它们通过隐码映射和若干通道分割空间特征变换（CS-SFT）层连接起来。在训练过程中，我们采用1) 中间恢复损失来移除复杂降质，2) 带有判别器的面部组件损失以增强面部细节，3) 保持身份的损失以保留人脸身份。

保留左侧分裂为单位矩阵以实现真实性和保真度的良好平衡。

局部组件判别器。局部判别器被提出以关注局部补丁分布[32, 47, 62]。当应用于人脸时，这些判别性损失会被施加在不同的语义面部区域上[43, 20]。我们引入的面部组件损失也采用了类似的设计，但进一步加入了基于学习到的判别特征的风格监督。

### 3. 方法学

#### 3.1 GFP-GAN 概述

在本节中，我们介绍了GFP-GAN框架。给定一张遭受未知退化的输入面部图像 $x$ ，盲面部恢复的目标是估计出一张高质量的图像 $\hat{y}$ ，使其在真实感和保真度方面尽可能接近地面真相图像 $y$ 。

GFP-GAN的整体框架如图2所示。GFP-GAN由一个降质去除模块（U-Net）和一个预训练的面部生成对抗网络（例如Style-GAN2 [36]）组成，后者作为先验条件。两者通过隐码映射和若干通道分割空间特征变换（CS-SFT）层连接起来。具体而言，降质去除模块旨在移除复杂的降质，并提取两类特征*i.e.*: 1) 隐式特征 $F_{latent}$ ，用于将输入图像映射到StyleGAN2中最接近的隐码；2) 多分辨率空间特征 $F_{spatial}$ ，用于调节StyleGAN2的特征。

随后， $F_{latent}$ 通过几个线性层映射到中间潜在码 $W$ 。鉴于该潜在码与输入图像非常接近，StyleGAN2可以生成*intermediate convolutional features*，记为 $F_{GAN}$ 。这些特征提供了面部细节在权重中的丰富捕捉。

训练后的生成对抗网络（GAN）。多分辨率特征 $F_{spatial}$ 被用于通过提出的CS-SFT层以由粗到精的方式对人脸GAN特征 $F_{GAN}$ 进行空间调制，从而在保持高保真度的同时实现逼真的效果。

在训练过程中，除了全局判别损失外，我们还引入了面部组件损失，并使用判别器来增强感知上重要的面部组件，如眼睛和嘴巴。为了保持身份特征，我们也采用了身份保留引导。

#### 3.2. 去劣化模块

现实世界中的盲人脸复原问题通常面临着复杂且严重的退化情况，这些退化通常是低分辨率、模糊、噪声和JPEG伪影的混合。降质去除模块旨在明确地移除上述退化，并提取“干净”的特征 $F_{latent}$ 和 $F_{spatial}$ ，从而减轻后续模块的压力。我们采用U-Net [56]结构作为我们的降质去除模块，因为它可以1) 增大感受野以消除大规模模糊，2) 生成多分辨率特征。具体形式如下：

$$F_{latent}, F_{spatial} = \text{U-Net}(x). \quad (1)$$

潜特征 $F_{latent}$ 用于将输入图像映射到StyleGAN2（第3.3节）中最接近的潜在代码。多分辨率空间特征 $F_{spatial}$ 用于调节StyleGAN2的特征（第3.4节）。

为了在训练早期阶段消除退化现象，我们在每个分辨率尺度上采用L1恢复损失进行中间监督。具体来说，我们还输出U-Net解码器中每个分辨率尺度的图像，并限制这些输出接近地面真相图像的金字塔结构。

### 3.3. 生成面部先验与潜在代码映射

预训练的面部GAN在其卷积权重中捕获了人脸分布，即生成先验[19,54]。我们利用这些预训练的面部GAN为我们的任务提供多样且丰富的面部细节。部署生成先验的一种典型方法是将输入图像映射到其最近似的潜在代码集 $Z$ ，然后通过预训练的GAN生成相应的输出[1,76,54,19]。然而，这些方法通常需要耗时的迭代优化以保持保真度。相反，我们不是直接生成最终图像，而是生成最接近人脸的潜在代码集合

*intermediate con-volutional features*  $F_{GAN}$ ，因为它们包含更多细节，并且可以通过输入特征进一步调节以获得更好的保真度（参见第3.4节）。

具体而言，给定输入图像（由U-Net生成，见公式1）的编码向量 $F_{latent}$ ，我们首先将其映射到中间潜在码 $\mathcal{W}$ 以更好地保留语义属性*i.e.*，该中间空间是从 $Z$ 通过几个多层感知器层（MLP）[76]转换而来的。然后，这些潜在码 $\mathcal{W}$ 依次通过预训练的生成对抗网络（GAN）中的每个卷积层，并为*each resolution scale*生成GAN特征。

$$\begin{aligned}\mathcal{W} &= \text{MLP}(F_{latent}), \\ F_{GAN} &= \text{StyleGAN}(\mathcal{W}).\end{aligned}\quad (2)$$

讨论：联合修复与色彩增强。生成模型捕捉了超越现实细节和生动纹理的多样且丰富的先验知识。例如，它们还包含了*color*类先验知识，这些可以在我们的任务中用于联合人脸修复和色彩增强。实际世界中的面部图像，如*e.g.*老照片，通常为黑白、复古黄色或暗淡色调。生成模型中的生动色彩先验使我们能够进行包括着色在内的色彩增强[72]。我们认为生成的人脸先验还包含了传统的几何先验[9, 69]、3D先验[16]等*etc.*，用于修复和操作。

### 3.4. 通道拆分空间特征变换

为了更好地保持图像的保真度，我们进一步利用U-Net产生的输入空间特征 $F_{spatial}$ （见公式1）来调节生成对抗网络（GAN）的特征 $F_{GAN}$ （见公式2）。在人脸修复中，保留来自输入的空间信息至关重要，因为这通常需要局部特性以保持保真度，并且要求在面部的不同空间位置进行自适应恢复。因此，我们采用空间特征变换（SFT）[63]，该方法生成用于空间维度上特征调节的仿射变换参数，在图像修复中已显示出其有效性，特别是在结合其他条件时[63, 44]以及在图像生成中的应用[55]。

具体而言，在每个分辨率尺度上，我们从输入特征生成一组仿射变换参数 $(\alpha, \beta)$ 。

通过几个卷积层进行特征提取 $F_{spatial}$ 。之后，通过对生成对抗网络（GAN）的特征 $F_{GAN}$ 进行缩放和偏移来完成调制，具体公式为：

$$\begin{aligned}\alpha, \beta &= \text{Conv}(F_{spatial}), \\ F_{output} &= \text{SFT}(F_{GAN}|\alpha, \beta) = \alpha \odot F_{GAN} + \beta.\end{aligned}\quad (3)$$

为了更好地平衡真实感和保真度，我们进一步提出了通道分割空间特征变换（CS-SFT）层，该层通过输入特征对部分GAN特征进行空间调制以提升保真度，并让剩余的GAN特征（负责增强真实感的部分）直接传递，如图2所示：

$$\begin{aligned}F_{output} &= \text{CS-SFT}(F_{GAN}|\alpha, \beta) \\ &= \text{Concat}[\text{Identity}(F_{GAN}^{split0}), \alpha \odot F_{GAN}^{split1} + \beta],\end{aligned}\quad (4)$$

其中， $F_{GAN}^{split0}$  和  $F_{GAN}^{split1}$  是从  $F_{GAN}$  按通道维度分割出来的特征，而  $\text{Concat}[\cdot, \cdot]$  表示拼接操作。

因此，CS-SFT 直接融合了先验信息，并通过输入图像有效调节，从而在纹理忠实度和保真度之间实现了良好的平衡。此外，由于 CS-SFT 调制所需的通道较少，类似于 GhostNet [23]，因此可以降低复杂性。

我们在每个分辨率尺度上进行通道分割的SFT层，最终生成一张恢复后的面部图像 $\hat{y}$ 。

### 3.5. 模型目标

我们的GFP-GAN训练目标包括：1) 重构损失，用于约束输出 $\hat{y}$ 接近真实值 $y$ ；2) 对抗损失，用于恢复逼真的纹理；3) 提出的面部组件损失，进一步增强面部细节；4) 身份保持损失。

重构损失。我们采用广泛使用的L1损失和感知损失[33, 41]作为我们的重构损失，定义如下：

$$\mathcal{L}_{rec} = \lambda_{l1} \|\hat{y} - y\|_1 + \lambda_{per} \|\phi(\hat{y}) - \phi(y)\|_1, \quad (5)$$

其中， $\phi$  是预训练的 VGG-19 网络 [59]，我们使用的是该网络在激活前的  $\{\text{conv1}, \dots, \text{conv5}\}$  特征图 [64]。 $\lambda_{l1}$  和  $\lambda_{per}$  分别表示 L1 损失和感知损失的权重。

对抗损失。我们采用对抗损失 $L_{adv}$ 来鼓励GFP-GAN倾向于自然图像流形中的解，并生成逼真的纹理。类似于StyleGAN2 [36]，采用了逻辑损失[18]：

$$\mathcal{L}_{adv} = -\lambda_{adv} \mathbb{E}_{\hat{y}} \text{softplus}(D(\hat{y})) \quad (6)$$

其中  $D$  表示判别器， $\lambda_{adv}$  表示对抗损失权重。

面部组件损失。为了进一步增强感知上重要的面部组件，我们引入了带有局部判别器的左眼面部组件损失。

右眼和嘴巴。如图2所示，我们首先使用ROI Align [24] 裁剪感兴趣区域。对于每个区域，我们训练单独且较小的局部判别器来区分恢复的补丁是否为真实数据，从而将这些补丁推向自然面部组件分布。

受文献[62]的启发，我们进一步引入了一种基于学习判别器的特征风格损失。与之前具有空间约束条件的特征匹配损失不同[62]，我们的特征风格损失尝试匹配真实和修复补丁的Gram矩阵统计量[15]。Gram矩阵计算特征相关性，并且通常能够有效捕捉纹理信息[17]。我们从学习到的局部判别器的多个层次中提取特征，并学会匹配这些来自真实和修复补丁中间表示的Gram统计量。经验表明，特征风格损失在生成逼真的面部细节和减少不愉快的伪影方面优于之前的特征匹配损失。

面部组件损失定义如下。第一项是判别损失[18]，第二项是特征风格损失。

$$\mathcal{L}_{comp} = \sum_{ROI} \lambda_{local} \mathbb{E}_{\hat{y}_{ROI}} [\log(1 - D_{ROI}(\hat{y}_{ROI}))] + \lambda_{fs} \|\text{Gram}(\psi(\hat{y}_{ROI})) - \text{Gram}(\psi(y_{ROI}))\|_1 \quad (7)$$

其中，ROI 是从组件集合

$\{\text{left\_eye}, \text{right\_eye}, \text{mouth}\}$  中提取的兴趣区域。 $D_{ROI}$  表示每个兴趣区域的局部判别器。 $\psi$  表示来自学习到的判别器的多分辨率特征。 $\lambda_{local}$  和  $\lambda_{fs}$  分别表示局部判别损失和特征风格损失的权重。

身份保持损失。我们借鉴了[31]中的方法，在模型中应用了身份保持损失。类似于感知损失[33]，我们基于输入人脸的特征嵌入定义该损失。具体来说，我们采用了预训练的人脸识别ArcFace[10]模型，该模型捕捉了最具辨识度的身份特征。身份保持损失强制恢复结果在紧凑的深度特征空间中与真实值的距离较小：

$$\mathcal{L}_{id} = \lambda_{id} \|\eta(\hat{y}) - \eta(y)\|_1, \quad (8)$$

其中， $\eta$  表示面部特征提取器，*i.e.* 为 ArcFace [10]， $\lambda_{id}$  表示保真损失的权重。

总体模型目标是上述各项损失的组合：

$$\mathcal{L}_{total} = \mathcal{L}_{rec} + \mathcal{L}_{adv} + \mathcal{L}_{comp} + \mathcal{L}_{id}. \quad (9)$$

损失超参数设置如下： $\lambda_{l1} = 0.1$ ， $\lambda_{per} = 1$ ， $\lambda_{adv} = 0.1$ ， $\lambda_{local} = 1$ ， $\lambda_{fs} = 200$ ， $\lambda_{id} = 10$ 。

## 4. 实验

### 4.1 数据集与实现

训练数据集。我们在FFHQ数据集[35]上训练我们的GFP-GAN，该数据集包含70,000张高质量图像。我们将所有图像在训练时调整为512像素大小。

我们的GFP-GAN是在合成数据上进行训练的，这些数据近似于真实的低质量图像，并且在推理时能够泛化到真实世界中的图像。我们遵循[46, 44]中的做法，采用以下退化模型来生成训练数据：

$$x = [(y \otimes k_\sigma) \downarrow_r + n_\delta]_{\text{JPEG}_q}. \quad (10)$$

首先，高质量图像  $y$  与高斯模糊核  $k_\sigma$  进行卷积运算，随后进行缩放操作，缩放因子为  $r$ 。之后，在图像中添加加性白高斯噪声  $n_\delta$ ，最后使用质量因子  $q$  对其进行JPEG 压缩。类似于 [44] 中的方法，对于每个训练对，我们分别从  $\{0.2 : 10\}$ 、 $\{1 : 8\}$ 、 $\{0 : 15\}$  和  $\{60 : 100\}$  中随机抽取  $\sigma$ 、 $r$ 、 $\delta$  和  $q$ 。在训练过程中，我们还添加颜色抖动以增强色彩效果。

测试数据集。我们构建了一个合成数据集和三个来源不同的真实数据集。所有这些数据集都与我们的训练数据集没有重叠。这里简要介绍如下。

- *CelebA-Test* 这是由其测试分区中的3,000张Celeb A-HQ图像组成的合成数据集[51]。生成方式与训练过程中相同。
- *LFW-Test*. LFW [29] 包含了质量较低的野外图像。我们将验证分区中每个身份的第一张图像进行分组，形成了1711张测试图像。
- *CelebChild-Test* 包含180张从互联网收集的名人的面部照片。这些照片质量较低，其中许多是黑白老照片。
- *WebPhoto-Test*. 我们从互联网上爬取了188张低质量的实物照片，并从中提取了407张人脸，构建了Web Photo测试数据集。这些照片具有多样且复杂的退化情况，其中一些是细节和色彩都严重退化的老照片。

实现。我们采用预训练的StyleGAN2[36]，其输出为512×49维度作为我们的生成面部先验模型。将StyleGAN2的通道乘数设置为1以减小模型尺寸。用于去除退化的UNet包含七次下采样和七次上采样操作，每次操作都配备一个残差块[25]。对于每个CS-SFT层，我们分别使用两个卷积层生成缩放和平移参数 $\alpha$ 和 $\beta$ 。

训练的小批量大小设置为12。我们通过水平翻转和颜色抖动来增强训练数据。我们认为左眼、右眼和嘴巴这三个部分在面部组件损失中具有感知重要性，因此对每个部件使用ROI align [24]进行裁剪以提取人脸特征。




图3: 在CelebA-Test数据集上进行盲人脸恢复的定性比较。我们的GFP-GAN生成了眼睛、嘴巴和头发等部位忠实的细节。请放大查看以获得最佳效果。




图4: 在CelebA-Test数据集上对比 $\times 4$ 人脸超分辨率的效果。我们的GFP-GAN能够恢复逼真的牙齿和准确的眼部视线方向。请放大查看以获得最佳效果。

我们在原始训练数据集中提供的地上训练模型。使用Adam优化器[38]进行总共80万次迭代的训练。学习率初始设置为 $2 \times 10^{-4}$ , 然后在第70万次和第75万次迭代时分别以2为因子衰减。我们使用PyTorch框架并在四块NVIDIA Tesla P40 GPU上进行模型训练。

#### 4.2. 与最新方法的比较

我们将我们的GFP-GAN与几种最先进的面部恢复方法进行了比较: HiFaceGAN [67]、DFDNet [44]、PSFRGAN [6]、Super-FAN [4]和Wan *et al* [61]。用于面部恢复的GAN逆向方法还包括PULSE [52] 和 mGANprior [19], 这些也被纳入了比较范围。此外, 我们还将GFP-GAN与图像恢复方法进行了对比: RCAN [74]、ESRGAN [64]和DeblurGANv2 [40], 并在我们的面部训练集上对它们进行微调以确保公平的比较。除了Super-FAN外, 其余均采用其*official*代码, 对于Super-FAN则使用了重新实现的版本。

为了评估, 我们采用了广泛使用的无参考感知度量标准: FID[27]和NIQE[53]。对于具有真实标签 (GT) 的CelebA-Test数据集, 我们也使用了像素级度量指标 (PSNR和SSIM) 以及感知度量指标 (LPIPS[73])。我们通过ArcFace[10]特征嵌入中的角度来衡量身份距离, 其中较小的值表示与真实标签更接近的身份。

合成CelebA测试。比较在两种设置下进行: 1) 无参考人脸恢复, 输入和输出具有相同的分辨率。2)  $4\times$ 人脸超分辨率。需要注意的是, 我们的方法可以处理上采样的图像。

表1: CelebA-Test数据集上盲人脸恢复的定量比较。红色和蓝色分别表示最佳和次佳性能。“\*”表示在我们的训练集上进行了微调。Deg. 表示身份距离。

| Methods                | LPIPS↓        | FID↓         | NIQE↓        | Deg.↓        | PSNR↑        | SSIM↑         |
|------------------------|---------------|--------------|--------------|--------------|--------------|---------------|
| Input                  | 0.4866        | 143.98       | 13.440       | 47.94        | 25.35        | 0.6848        |
| DeblurGANv2* [40]      | <u>0.4001</u> | 52.69        | 4.917        | <u>39.64</u> | <b>25.91</b> | <b>0.6952</b> |
| Wan <i>et al.</i> [61] | 0.4826        | 67.58        | 5.356        | 43.00        | 24.71        | 0.6320        |
| HiFaceGAN [67]         | 0.4770        | 66.09        | 4.916        | 42.18        | 24.92        | 0.6195        |
| DFDNet [44]            | 0.4341        | 59.08        | <u>4.341</u> | 40.31        | 23.68        | 0.6622        |
| PSFRGAN [6]            | 0.4240        | <u>47.59</u> | 5.123        | 39.69        | 24.71        | 0.6557        |
| mGANprior [19]         | 0.4584        | 82.27        | 6.422        | 55.45        | 24.30        | 0.6758        |
| PULSE [52]             | 0.4851        | 67.56        | 5.305        | 69.55        | 21.61        | 0.6200        |
| <b>GFP-GAN (ours)</b>  | <b>0.3646</b> | <b>42.62</b> | <b>4.077</b> | <b>34.60</b> | 25.08        | 0.6777        |
| GT                     | 0             | 43.43        | 4.292        | 0            | $\infty$     | 1             |

作为输入用于面部超分辨率。

表1和表2展示了每种设置下的定量结果。在两种设置下, GFP-GAN均获得了最低的LPIPS值, 表明我们的结果在感知上接近真实情况。此外, GFP-GAN还取得了最低的FID和NIQE值, 这说明其输出与真实的面部分布和自然图像分布分别具有较小的距离。除了感知性能外, 我们的方法还能更好地保留身份特征, 这一点从最小的脸部特征嵌入角度可以得到证明。需要注意的是: 1) 我们方法的FID和NIQE值低于GT, 并不意味着我们的表现优于GT, 因为这些“感知”指标与人类评分在粗略尺度上具有良好的相关性; 2) 像素级别的PSNR和SSIM度量并不很好地反映人类观察者的主观评价[2, 41], 且我们的模型在这两个指标上的表现不佳。

图3和图4展示了定性结果。1) 得益于强大的生成面部先验, 我们的GFP-GAN能够恢复眼睛 (瞳孔和睫毛)、牙齿等部位的忠实细节。2) 我们的方法在修复过程中将人脸视为整体, 并能生成逼真的头发, 而依赖于组件字典 (DFD-Net) 或解析图 (PSFRGAN) 的先前方法无法产生忠实的头发纹理 (图3第2行)。3) GFP-GAN能够保持保真度, 它还能生成自然闭合的嘴唇。



Figure 5: Qualitative comparisons on three **real-world** datasets. **Zoom in for best view.**

表2: CelebA-Test数据集上针对4×人脸超分辨率的定量比较。红色和蓝色分别表示最佳和次佳性能。“\*”表示在我们的训练集上进行了微调。Deg. 表示身份距离。

| Methods               | LPIPS↓        | FID↓         | NIQE ↓       | Deg.↓        | PSNR↑        | SSIM↑         |
|-----------------------|---------------|--------------|--------------|--------------|--------------|---------------|
| Bicubic               | 0.4834        | 148.87       | 10.767       | 49.60        | 25.377       | 0.6985        |
| RCAN* [74]            | 0.4159        | 93.66        | 9.907        | <u>38.45</u> | <b>27.24</b> | <b>0.7533</b> |
| ESRGAN* [64]          | <u>0.4127</u> | <u>49.20</u> | 4.099        | <u>51.21</u> | 23.74        | 0.6319        |
| Super-FAN [4]         | 0.4791        | 139.49       | 10.828       | 49.14        | 25.28        | 0.7033        |
| <b>GFP-GAN (ours)</b> | <b>0.3653</b> | <b>42.36</b> | <b>4.078</b> | <b>34.67</b> | 25.04        | 0.6744        |
| GT                    | 0             | 43.43        | 4.292        | 0            | ∞            | 1             |

无需像PSFRGAN那样强制添加牙齿（图3第2行）。在图4中，GFP-GAN也能合理恢复眼睛的视线方向。

现实世界中的LFW、CelebChild和WedPhoto-Test数据集。为了测试模型的泛化能力，我们在三个不同的真实世界数据集上对其进行了评估。定量结果见表3。我们的GFP-GAN在所有三个真实世界数据集中均表现出色，展示了其卓越的泛化能力。尽管PULSE [52]也能获得较高的感知质量（较低的FID分数），但它无法保持面部身份信息。

表3: *real-world* LFW、CelebChild和WebPhoto的定量比较。红色和蓝色分别表示最佳和次佳性能。“\*”表示在我们的训练集上进行了微调。Deg. 表示身份距离。

| Dataset                | LFW-Test     |              | CelebChild    |              | WebPhoto     |              |
|------------------------|--------------|--------------|---------------|--------------|--------------|--------------|
| Methods                | FID↓         | NIQE ↓       | FID↓          | NIQE ↓       | FID↓         | NIQE ↓       |
| Input                  | 137.56       | 11.214       | 144.42        | 9.170        | 170.11       | 12.755       |
| DeblurGANv2* [40]      | 57.28        | 4.309        | 110.51        | 4.453        | 100.58       | 4.666        |
| Wan <i>et al.</i> [61] | 73.19        | 5.034        | 115.70        | 4.849        | 100.40       | 5.705        |
| HiFaceGAN [67]         | 64.50        | 4.510        | 113.00        | 4.855        | 116.12       | 4.885        |
| DFDNet [44]            | 62.57        | <u>4.026</u> | 111.55        | <u>4.414</u> | 100.68       | 5.293        |
| PSFRGAN [6]            | <u>51.89</u> | 5.096        | <u>107.40</u> | 4.804        | 88.45        | 5.582        |
| mGANprior [19]         | 73.00        | 6.051        | 126.54        | 6.841        | 120.75       | 7.226        |
| PULSE [52]             | 64.86        | 5.097        | <b>102.74</b> | 5.225        | <b>86.45</b> | 5.146        |
| <b>GFP-GAN (ours)</b>  | <b>49.96</b> | <b>3.882</b> | 111.78        | <b>4.349</b> | <u>87.35</u> | <b>4.144</b> |

如图5所示。

如图5所示，GFP-GAN能够联合进行真实生活照片中的面部修复和色彩增强，利用强大的生成先验。我们的方法能够在复杂的现实世界退化情况下产生合理且逼真面部图像，而其他方法则无法恢复忠实的面部细节或会产生不自然的结果。

表4: 在CelebA-Test数据集上进行盲人脸恢复时的消融实验结果。

| Configuration                 | LPIPS↓        | FID↓         | NIQE↓        | Deg.↓        |
|-------------------------------|---------------|--------------|--------------|--------------|
| Our GFP-GAN with SC-SFT       | <b>0.3646</b> | <b>42.62</b> | <b>4.077</b> | <b>34.60</b> |
| a) No spatial modulation      | 0.550 (↑)     | 60.44 (↑)    | 4.183 (↑)    | 74.76 (↑)    |
| b) Use SFT                    | 0.387 (↑)     | 47.65 (↑)    | 4.146(↑)     | 34.38 (↓)    |
| c) w/o GFP                    | 0.379 (↑)     | 48.47 (↑)    | 4.153 (↑)    | 35.04 (↑)    |
| d) – Pyramid Restoration Loss | 0.369 (↑)     | 45.17 (↑)    | 4.284 (↑)    | 35.50 (↑)    |

事实（尤其是在图5中的WebPhoto-Test部分）表明，GFP-GAN在头发和耳朵等面部特征上的表现也优于其他方法。这是因为GFP先验考虑的是整个脸部而非单独的部分。借助SC-SFT层，我们的模型能够实现高保真度。如图5的最后一行所示，大多数先前的方法无法恢复闭合的眼睛，而我们则能成功地以较少的伪影进行还原。

### 4.3. 消融实验

CS-SFT 层。如表4 [配置a)]和图6所示，当我们移除空间调制层*i.e.*，仅保留不包含空间信息的潜在代码映射时，即使使用了保持身份损失（高LIPS评分和大Deg.），恢复的人脸也无法保留面部识别特征。因此，CS-SFT 层中使用的多分辨率空间特征对于保持保真度至关重要。当我们把 CS-SFT 层切换为简单的 SFT 层 [表4的配置b)]时，我们观察到：1) 所有指标上的感知质量下降；2) 保留了更强的身份信息（Deg.更小），因为输入图像特征对所有调制后的特征施加影响，并且输出偏向于退化的输入，从而导致更低的感知质量。相比之下，CS-SFT 层通过调节部分特征提供真实感和保真度的良好平衡。

预训练GAN作为GFP。预训练GAN提供了丰富多样的特征用于恢复。如果不使用生成面部先验，则如表4[配置c)]和图6所示，性能会下降。

金字塔恢复损失。金字塔恢复损失被应用于降质去除模块中，增强了对现实世界复杂降质的恢复能力。如果没有这一中间监督机制，在后续调制中的多分辨率空间特征可能仍然存在降质问题，从而导致性能不佳，如表4 [配置d)] 和图6所示。

面部组件损失。我们比较了以下四种情况的结果：1) 移除所有面部组件损失，2) 仅保留组件判别器，3) 如文献[62]所述添加额外的特征匹配损失，4) 基于Gram统计量采用额外的特征风格损失[15]。图7显示，带有特征风格损失的组件判别器能够更好地捕捉眼睛分布并恢复合理的细节。




图6: CS-SFT层、GFP先验及金字塔恢复损失的消融研究。放大查看最佳效果。




图7: 面部组件损失的消融研究。在图中， $D$ 、 $fm$ 、 $fs$  表示组件判别器和特征



Figure 8: Results on dark-skinned faces.




图9: 我们的模型的局限性。同时也展示了PSFR-GAN[6]的结果。

### 4.4. 讨论与限制

训练偏差。我们的方法在大多数肤色较深的脸部图像和各种人群中表现良好（见图8），因为我们的方法同时使用了预训练的生成对抗网络（GAN）和输入图像特征进行调制。此外，我们采用重构损失和身份保持损失来限制输出以保留与输入的一致性。然而，当输入图像为灰度图像时，面部颜色可能会出现偏差（见图8中的最后一个例子），因为输入中不包含足够的色彩信息。因此，需要一个多样且平衡的数据集

限制。如图9所示，当真实图像的退化严重时，GFP-GAN恢复的人脸细节会出现扭曲和伪影。我们的方法对于非常大的姿态变化也会产生不自然的结果。这是因为合成退化和训练数据分布与现实世界中的情况不同。一种可能的方法是从真实数据中学习这些分布，而不仅仅是使用合成数据，这留待未来的工作来完成。

## 5. 结论

我们提出了一种基于GFP-GAN框架的方法，该方法利用了丰富且多样化的生成面部先验知识，以应对具有挑战性的无参考人脸修复任务。通过在修复过程中引入通道分割的空间特征变换层，我们将这种先验知识融入到了恢复过程之中，从而实现了真实感和保真度的良好平衡。大量的对比实验表明，GFP-GAN在实际图像的人脸修复与色彩增强方面表现出卓越的能力，并且优于现有的方法。

## 参考文献

[1] Rameen Abdal, Yipeng Qin 和 Peter Wonka. Image2stylegan: 如何将图像嵌入到 StyleGAN 的潜在空间中? 在 *ICCV*, 2019年. 第2、4页 [2] Yochai Blau, Roey Mechrez, Radu Timofte, Tomer Michaeli 和 Lihi Zelnik-Manor. 2018 PIRM 感知图像超分辨率挑战赛. 在 *ECCV*, 2018年. 第6页 [3] Andrew Brock, Jeff Donahue 和 Karen Simonyan. 大规模GAN训练用于高保真自然图像合成. *arXiv preprint arXiv:1809.11096*, 2018年. 第2页 [4] Adrian Bulat 和 Georgios Tzimiropoulos. Super-FAN: 使用GAN在任意姿态下对真实世界低分辨率面部进行集成的地标定位和超分辨率处理. 在 *CVPR*, 2018年. 第6、7页 [5] Qingxing Cao, Liang Lin, Yukai Shi, Xiaodan Liang 和 Guanbin Li. 基于深度强化学习的关注感知人脸幻觉生成. 在 *CVPR*, 2017年. 第2页 [6] Chaofeng Chen, Xiaoming Li, Lingbo Yang, Xianhui Lin, Lei Zhang 和 Kwan-Yee K. Wong. 进行盲态面部修复的渐进式语义感知风格转换. *arXiv:2009.08709*, 2020年. 第1、2、6、7、8页 [7] Jingwen Chen, Jiawei Chen, Hongyang Chao 和 Ming Yang. 基于生成对抗网络噪声建模的图像盲态去噪处理. 在 *CVPR*, 2018年. 第2页 [8] Yunpeng Chen, Jianan Li, Huaxin Xiao, Xiaojie Jin, Shuicheng Yan 和 Jiahui Feng. 双路径网络. 在 *NeurIPS*, 2017年. 第2页 [9] Yu Chen, Ying Tai, Xiaoming Liu, Chunhua Shen 和 Jian Yang. FSRNet: 基于面部先验的端到端学习人脸超分辨率处理. 在 *CVPR*, 2018年. 第1、2、4页 [10] Jiankang Deng, Jia Guo, Nannan Xue 和 Stefanos Zafeiriou. ArcFace: 用于深度人脸识别的加性角度余量损失函数. 在 *CVPR*, 2019年. 第5、6页 [11] Berk Dogan, Shuhang Gu 和 Radu Timofte. 无面部地标引导的示例导向人脸图像超分辨率处理. 在 *CVPRW*, 2019年. 第1、2页 [12] Chao Dong, Yubin Deng, Chen Change Loy 和 Xiaoou Tang. 使用深度卷积网络进行压缩伪影减少. 在 *ICCV*, 2015年. 第1、2页 [13] Chao Dong, Chen Change Loy, Kaiming He 和 Xiaoou Tang. 学习用于图像超分辨率处理的深度卷积网络. 在 *ECCV*, 2014年. 第1、2页 [14] Leonardo Galteri, Lorenzo Seidenari, Marco Bertini 和 Alberto Del Bimbo. 深度生成对抗压缩伪影去除. 在 *ICCV*, 2017年. 第2页 [15] Leon A Gatys, Alexander S Ecker 和 Matthias Bethge. 使用卷积神经网络进行图像风格转换. 在 *CVPR*, 2016年. 第5、8页 [16] Baris Gecer, Stylianos Ploumpis, Irene Kotsia 和 Stefanos Zafeiriou. GanFit: 用于高保真3D面部重建的生成对抗网络拟合. 在 *CVPR*, 2019年. 第4页 [17] Muhammad Waleed Gondal, Bernhard Schölkopf 和 Michael Hirsch. 单幅图像超分辨率处理中纹理转移的不合理有效性. 在 *ECCV*, 2018年. 第5页 [18] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville 和

Yoshua Bengio. 生成对抗网络. 在 *NeurIPS*, 2014年. 第2、4、5章 [19] 金锦顾, 沈玉俊, 周博磊. 使用多码GAN先验进行图像处理. 在 *CVPR*, 2020年. 第2、4、6、7章 [20] 邱乔, 王冠智, Chiu Mang Tik, 太宇维, 汤志刚. Ldn: 局部对抗解构网络用于面部化妆和卸妆. 在 *ICCV*, 2019年. 第3章 [21] 顾俊, 赵泓洋. 建立双域表示以减少压缩失真. 在 *ECCV*, 2016年. 第2章 [22] 郭勇, 陈剑, 王景东, 陈麒, 曹杰张, 邓泽帅, 徐雁武, 谈明奎. 闭环重要性: 用于单图像超分辨率的双回归网络. 在 *CVPR*, 2020年. 第2章 [23] 韩凯, 王云鹤, 田奇, 郭建远, 徐春静, 谢畅. Ghostnet: 更多来自低成本操作的功能. 在 *CVPR*, 2020年. 第2、4章 [24] Kaiming He, Georgia Gkioxari, Piotr Dollár, 和 Ross Girshick. Mask R-CNN. 在 *ICCV*, 2017年. 第5章 [25] Kaiming He, Xiangyu Zhang, Shaoqing Ren, 和 Jian Sun. 深度残差学习用于图像识别. 在 *CVPR*, 2016年. 第5章 [26] Majed El Helou, Ruofan Zhou, 和 Sabine Süsstrunk. 随机频率掩蔽以改进超分辨率和去噪网络. 在 *ECCV*, 2020年. 第2章 [27] Martin Heusel, Hubert Ramsauer, Thomas Unterthiner, Bernhard Nessler, 和 Sepp Hochreiter. GANs 通过双时间尺度更新规则训练收敛于局部纳什均衡. 在 *NeurIPS*, 2017年. 第6章 [28] Andrew G Howard, Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto, 和 Hartwig Adam. MobileNets: 用于移动视觉应用的高效卷积神经网络. *arXiv:1704.04861*, 2017年. 第2章 [29] Gary B. Huang, Manu Ramesh, Tamara Berg, 和 Erik Learned-Miller. Labeled Faces in the Wild: 一个研究不受约束环境下面部识别的数据集. 技术报告, 马萨诸塞大学阿默斯特分校, 2007年. 第5章 [30] 黄华博, 何然, 孙振安, 和 谭铁牛. Wavelet-SRNet: 一种基于小波的CNN用于多尺度面部超分辨率. 在 *ICCV*, 2017年. 第2章 [31] 黄睿, 张舒, 李天宇, 何然. 超越面部旋转: 全局和局部感知GAN用于逼真且身份保持的正面视图合成. 在 *CVPR*, 2017年. 第5章 [32] Satoshi Iizuka, Edgar Simo-Serra, 和 Hiroshi Ishikawa. 全局与局部一致性的图像完成. *ACM Transactions on Graphics (ToG)*, 第36卷(4): 1–14, 2017年. 第3章 [33] Justin Johnson, Alexandre Alahi, 和 Li Fei-Fei. 感知损失用于实时风格转换和超分辨率. 在 *ECCV*, 2016年. 第4、5章 [34] Tero Karras, Timo Aila, Samuli Laine, 和 Jaakko Lehtinen. 逐步增长GAN以提高质量、稳定性和多样性. 在 *ICLR*, 2018年. 第2章 [35] Tero Karras, Samuli Laine, 和 Timo Aila. 基于风格的生成器架构用于生成对抗网络. 在 *CVPR*, 2018年. 第2、5章

[36] Tero Karras, Samuli Laine, Miika Aittala, Janne Hellsten, Jaakko Lehtinen 和 Timo Aila. StyleGAN 图像质量分析与改进。在 *CVPR*, 2020 年。第 2、3、4、5 章节引用。[37] Deokyun Kim, Minseon Kim, Gihyun Kwon 和 Dae-Shik Kim。通过面部特征关注的渐进式人脸超分辨率方法。在 *BMVC*, 2019 年。第 2 章节引用。[38] Diederik P Kingma 和 Jimmy Ba. Adam: 一种随机优化方法。在 *ICLR*, 2015 年。第 6 章节引用。[39] Orest Kupyn, Volodymyr Budzan, Mykola Mykhailych, Dmytro Mishkin 和 Jiří Matas。Deblurgan: 基于条件对抗网络的盲运动去模糊方法。在 *CVPR*, 2018 年。第 1、2 章节引用。[40] Orest Kupyn, Tetiana Martyniuk, Junru Wu 和 Zhangyang Wang。Deblurgan-v2: 更快更优的盲运动去模糊方法。在 *ICCV*, 2019 年。第 6、7 章节引用。[41] Christian Ledig, Lucas Theis, Ferenc Huszár, Jose Caballero, Andrew Cunningham, Alejandro Acosta, Andrew Aitken, Alykhan Tejani, Johannes Totz, Zehan Wang 等。基于生成对抗网络的单幅图像超分辨率照片级真实感增强方法。在 *CVPR*, 2017 年。第 2、4、6 章节引用。[42] Stamatios Lefkimmiatis。非局部颜色图像去噪卷积神经网络方法。在 *CVPR*, 2017 年。第 2 章节引用。[43] Tingting Li, Ruihe Qian, Chao Dong, Si Liu, Qiong Yan, Wenwu Zhu 和 Liang Lin。BeautyGAN: 基于深度生成对抗网络的实例级面部妆容迁移方法。在 *ACM MM*, 2018 年。第 3 章节引用。[44] Xiaoming Li, Chaofeng Chen, Shangchen Zhou, Xianhui Lin, Wangmeng Zuo 和 Lei Zhang。基于深度多尺度组件字典的盲面部恢复方法。在 *ECCV*, 2020 年。第 1、2、4、5、6、7 章节引用。[45] Xiaoming Li, Wenyu Li, Dongwei Ren, Hongzhi Zhang, Meng Wang 和 Wangmeng Zuo。基于多示例图像和自适应空间特征融合的增强盲面部恢复方法。在 *CVPR*, 2020 年。第 1、2 章节引用。[46] Xiaoming Li, Ming Liu, Yuting Ye, Wangmeng Zuo, Liang Lin 和 Ruigang Yang。学习扭曲引导的盲面部恢复方法。在 *ECCV*, 2018 年。第 1、2、5 章节引用。[47] Yijun Li, Sifei Liu, Jimei Yang 和 Ming-Hsuan Yang。生成式人脸补全方法。在 *CVPR*, 2017 年。第 3 章节引用。[48] Bee Lim, Sanghyun Son, Heewon Kim, Seungjun Nah 和 Kyoung Mu Lee。增强深度残差网络单幅图像超分辨率方法。在 *CVPRW*, 2017 年。第 1、2 章节引用。[49] Ding Liu, Bihan Wen, Yuchen Fan, Chen Change Loy 和 Thomas S Huang。非局部递归网络图像恢复方法。在 *NeurIPS*, 2018 年。第 2 章节引用。[50] Jie Liu, Wenjie Zhang, Yuting Tang, Jie Tang 和 Gangshan Wu。残差特征聚合网络单幅图像超分辨率方法。在 *CVPR*, 2020 年。第 2 章节引用。[51] Ziwei Liu, Ping Luo, Xiaoqiang Wang 和 Xiaoou Tang。Deep Learning Face Attributes in the Wild 方法。在 *ICCV*, 2015 年。第 5 章节引用。[52] Sachit Menon, Alexandru Damian, Shijia Hu, Nikhil Ravi 和 Cynthia Rudin。PULSE: 基于生成模型潜在空间探索的自监督照片上采样方法。在 *CVPR*, 2020 年。第 1、2、6、7 章节引用。[53] Anish Mittal, Rajiv Soundararajan 和 Alan C Bovik。构建“完全盲”的图像质量分析器。 *IEEE Signal processing letters*, 20(3):209–212, 2012 年。第 6 章节引用。

[54] 潘兴刚, 战晓航, 戴波, 林达华, Loy Chen Change 和 Luo Ping。利用深度生成先验进行多功能图像恢复和处理。在 *ECCV* 中, 2020 年。第 2、4 章 [55] Park Taesung, Liu Ming-Yu, Wang Ting-Chun 和 Zhu Jun-Yan。基于空间自适应归一化的语义图像合成。在 *CVPR* 中, 2019 年。第 2、4 章 [56] Ronneberger Olaf, Fischer Philipp 和 Brox Thomas。U-net: 用于生物医学图像分割的卷积网络。在 *International Conference on Medical Image Computing and Computer-Assisted Intervention* 中, 2015 年。第 3 章 [57] Sajjadi Mehdi SM, Scholkopf Bernhard 和 Hirsch Michael。Enhancenet: 通过自动化纹理合成实现单图像超分辨率。在 *ECCV* 中, 2017 年。第 2 章 [58] Shen Ziyi, Lai Wei-Sheng, Xu Tingfa, Kautz Jan 和 Yang Ming-Hsuan。深度语义人脸去模糊化。在 *CVPR* 中, 2018 年。第 1、2 章 [59] Simonyan Karen 和 Zisserman Andrew。非常深的卷积网络用于大规模图像识别。在 *ICLR* 中, 2015 年。第 4 章 [60] Timofte Radu, Agustsson Eirikur, Van Gool Luc, Yang Ming-Hsuan 和 Zhang Lei。NTIRE 2017 单图像超分辨率挑战: 方法与结果。在 *CVPRW* 中, 2017 年。第 2 章 [61] Wan Ziyu, Zhang Bo, Chen Dongdong, Zhang Pan, Chen Dong, Liao Jing 和 Wen Fang。让旧照片重现生机。在 *CVPR* 中, 2020 年。第 1、6、7 章 [62] Wang Ting-Chun, Liu Ming-Yu, Zhu Jun-Yan, Tao Andrew, Kautz Jan 和 Catanzaro Bryan。基于条件生成对抗网络的高分辨率图像合成与语义操作。在 *CVPR* 中, 2018 年。第 3、5、8 章 [63] Wang Xintao, Yu Ke, Dong Chao 和 Loy Chen Change。利用深度空间特征变换恢复真实纹理的图像超分辨率技术。在 *CVPR* 中, 2018 年。第 2、4 章 [64] Wang Xintao, Yu Ke, Wu Shixiang, Gu Jinjin, Liu Yihao, Dong Chao, Qiao Yu 和 Loy Chen Change。ESRGAN: 增强的超分辨率生成对抗网络。在 *ECCVW* 中, 2018 年。第 2、4、6、7 章 [65] Xu Li, Ren Jimmy S, Liu Ce 和 Jia Jiaya。深度卷积神经网络用于图像去卷积。在 *NeurIPS* 中, 2014 年。第 2 章 [66] Xu Xiangyu, Sun Deqing, Pan Jinshan, Zhang Yujin, Pfister Hanspeter 和 Yang Ming-Hsuan。学习模糊人脸和文本图像的超分辨率技术。在 *ICCV* 中, 2017 年。第 2 章 [67] Yang Lingbo, Liu Chang, Wang Pan, Wang Shanshe, Ren Peiran, Ma Siwei 和 Gao Wen。HIFACEGAN: 通过协作抑制和补充进行面部修复。 *ACM Multimedia* 中, 2020 年。第 1、6、7 章 [68] Yu Ke, Wang Xintao, Dong Chao, Tang Xiaoou 和 Loy Chen Change。Path-restore: 学习网络路径选择用于图像恢复。 *arXiv:1904.10343* 中, 2019 年。第 2 章 [69] Yu Xin, Fernando Basura, Ghanem Bernard, Porikli Fatih 和 Hartley Richard。基于面部组件热图的面部超分辨率技术。在 *ECCV* 中, 页码 217–233, 2018 年。第 1、2、4 章 [70] Yu Xin, Fernando Basura, Hartley Richard 和 Porikli Fatih。利用补充属性实现非常低分辨率面部图像的超分辨率技术。在 *CVPR* 中, 2018 年。第 2 章

[71] 张凯, 左旺孟, 陈云瑾, Meng Deyu 和 Zhang Lei。超越高斯去噪器: 深度 CNN 的残差学习在图像去噪中的应用。 *IEEE TIP*, 26(7):3142–3155, 2017. 1, 2[72] Richard Zhang, Phillip Isola 和 Alexei A Efros。多彩图像着色。在 *ECCV* 中, 2016. 4[73] Richard Zhang, Phillip Isola, Alexei A Efros, Eli Shechtman 和 Oliver Wang。深度特征作为感知度量的不合理有效性。在 *CVPR* 中, 2018. 6[74] 张玉伦, 李坤鹏, 李凯, 王立晨, 钟斌能 和 付云。使用非常深的残差通道注意网络进行图像超分辨率处理。在 *ECCV* 中, 2018. 2, 6, 7[75] 赵晓乐, 张玉伦, 张涛 和 邹雪明。单 MR 图像超分辨率的信道分割网络。 *IEEE Transactions on Image Processing*, 28(11):5649–5662, 2019. 2[76] 朱佳鹏, 沈宇俊, 赵德利 和 周博磊。域内 GAN 反演用于真实图像编辑。在 *ECCV* 中, 2020. 2, 4[77] 朱世展, 刘思飞, Loy Chen Change 和 Tang Xiaoou。深度级联双网络面部超分辨率处理。在 *ECCV* 中, 2016. 2